Wszechstronna analiza wieku kobiet, narażonych na choroby psychiczne

Sofiya Dreka
nr albumu 180829
Matematyka stosowana i analiza danych, 1 rok

1 marca 2026

Streszczenie

Spis treści

1 Wstęmp **2**

2 Analiza **3**
2.1 Dane źródłowe . . . 3
2.2 Średnia, kwartyle i dominanta . . . 4
2.3 Obliczenia . . . 6

3 Wykresy **8**
3.1 Wykres pudełkowy . . . 8
3.2 Histogram liczebności . . . 8
3.3 Histogram liczebności skumulowanych . . . 8
3.4 Wielobok liczebności . . . 9
3.5 Wielobok liczebności skumulowanych . . . 9

4 Wyniki projektu **10**
4.1 Podsumowsnie obliczeń . . . 10
4.2 Podsumowanie wykresów . . . 11

Literatura **11**

Spis tabel

1 Dane źródłowe . . . 3
2 Szereg rozdzielczy . . . 4
3 Szereg rozdzielczy i wartości skumulowane . . . 4
4 Środek przedziału . . . 5
5 Obliczenia z potęgami . . . 6

1 Wstęmp

Temat zdrowia psychicznego kobiet, pomimo licznych badań, dopiero od niedawna jest chętnie brany pod uwagę jako obszar priorytetowy dla Światowego Towarzystwa Psychiatrycznego. Zainteresowanie tą gałęzią psychiatrii nie jest przypadkowe, gdyż objawy, tolerancja, przyczyny i, co najważniejsze, manifestacja bardzo różnią się od tych samych cech chorób psychicznych u mężczyzn. Kobiety są około 2 razy bardziej narażone na zaburzenia lękowe i depresyjne, a w sytuacjach stresowych są bardziej podatne na reakcje intrakarne, nadmierne uważanie się za odpowiedzialne za niekorzystny wynik, co prowadzi do zaburzenia mechanizmów adaptacyjnych.

Temat ten jest wieloaspektowy i ciekawy do zbadania. Wykorzystując dostępne dane zebrane przez doświadczonych lekarzy, profesorów i po prostu osoby, które chcą lepiej zrozumieć przyczyny pewnych działań i reakcji milionów kobiet na całym świecie, możemy przeprowadzić szczegółową analizę interesujących nas zagadnień. W tym projekcie będę analizować wiek kobiet doświadczających chorób psychicznych, takich jak depresja, zaburzenia lękowe, choroba afektywna dwubiegunowa i inne. Pokażę, jaki wiek jest najbardziej typowy dla rozwoju problemów psychicznych, jaki odsetek kobiet w każdym z badanych grup wiekowych dotyka choroby i wiele więcej. Jako źródło danych posłużę się samodzielnie zebranymi informacjami pzez ochotników na temat chorób psychicznych zarówno u mężczyzn, jak i u kobiet [1]. W ramach tego zbioru danych przeprowadzono wywiady z 500 osobami, z czego 234 to kobiety, które będą dla nas interesujące.[2]

Temat ten zwrócił moją uwagę rok temu po przeczytaniu książki o kobiecej depresji autorstwa wykwalifikowanego psychologa Ursuli Nuber [1], która pisze:

> *"Dlatego też pierwsza teza tej książki brzmi: Depresja kobiet jest chorobą wywołaną stresem: kobiety narażone są na działanie specyficznych stresorów, które rzadziej lub wcale nie spotykane są w życiu mężczyzn".*

Często zaczynałam zwracać uwagę na opisane przez nią cechy zachowań znanych mi kobiet i zadawać siebie pytania o przyczyny, które do tego doprowadziły. Dlatego teraz, mając wiedzę na temat tego, jak można przeprowadzić analizę, z przyjemnością wracam do tego tematu, aby pogłębić swoją wiedzę w tym zakresie i uzyskać nowe wyniki do przemyślenia.

[1] Tu można kliknąć i zobaczyć źródło

[2] Mental Health Diagnosis and Treatment Monitoring, Kaggle (https://www.kaggle.com/datasets/uom190346a/mental-health-diagnosis-and-treatment-monitoring)

2 Analiza

2.1 Dane źródłowe

43	45	52	35	55	49	22	60	35	39	55	18
40	41	51	47	31	34	31	54	34	44	20	25
55	46	**60**	47	**18**	20	51	55	57	19	41	31
34	31	45	41	59	44	37	37	49	36	52	24
32	50	32	37	40	49	35	21	46	34	35	45
21	40	31	42	54	51	26	51	22	19	57	57
21	43	56	57	60	41	31	30	33	46	20	49
42	41	22	41	56	40	52	20	50	56	51	39
54	46	55	21	58	22	35	28	31	32	52	60
46	31	43	45	53	55	56	60	29	18	37	58
23	38	49	22	27	18	33	50	24	44	35	36
38	28	22	21	24	54	49	42	60	52	24	24
28	29	40	26	54	20	59	32	45	25	48	27
52	35	43	27	24	38	44	43	19	58	36	33
41	56	44	55	43	24	28	51	51	51	53	
53	41	19	26	59	20	51	42	57	31	35	
19	23	30	21	46	26	30	25	27	32	39	
41	28	58	52	40	44	51	24	21	33	52	
39	35	20	56	51	30	51	20	27	35	20	
27	39	45	47	21	55	58	32	54	45	21	

Tabela 1: Dane źródłowe

Mając dane źródłowe, możemy uzyskać wartości maksymalne i minimalne, a następnie obliczyć rozstępmp.

$$X_{max} = 60$$
$$X_{min} = 18$$

Rozstępmp wynosi:

$$R = X_{max} - X_{min}$$
$$R = 60 - 18 = 42$$

Teraz możemy utworzyć szereg rozdzielczy. W tym celu przydzieliłam 9 przedziałów klasowych z długością przedziału klasowego 5.

Dlaczego?

Bo mamy:

liczebność próby $n = 234$

k– liczba klas

R– rozstępmp

$$k \approx \sqrt{234}$$
$$R \approx k \cdot h$$
$$42 \approx 9 \cdot 5$$

Wiek kobiet	**granica dolna**	**granica górna**	**ni**
15-20	15	20	18
20-25	20	25	28
25-30	25	30	21
30-35	30	35	33
35-40	35	40	21
40-45	40	45	32
45-50	45	50	19
50-55	50	55	37
55-60	55	60	25
			234

Tabela 2: Szereg rozdzielczy

2.2 Średnia, kwartyle i dominanta

Aby uzyskać wartości kolejnych parametrów musimy obliczyć liczebności skumulowane. Razem możemy obliczyć częstość, aby dowiedzieć się, jaki procent kobiet w danym wieku stanowią wszystkie analizowane kobiety, oraz częstość skumulowaną.

Do obliczeń liczebności skumulowanych ($N_i skumulowane$, dalej prosta N_i) skorzystamy z formuły:

$$N_i = n_{i1} + n_{i+1}$$

Częstość obliczamy w następujący sposób (niech c będzie częstością oraz C – częstością skumulowaną):

$$c = \frac{n_i}{n}$$

$$C = \frac{N_i}{n}$$

Wiek kobiet	**granica dolna**	**granica górna**	**ni**	**Ni**	**c**	**C**
15-20	15	20	18	18	8%	8%
20-25	20	25	28	46	12%	20%
25-30	25	30	21	67	9%	29%
30-35	30	35	33	100	14%	43%
35-40	35	40	21	121	9%	52%
40-45	40	45	32	153	14%	65%
45-50	45	50	19	172	8%	74%
50-55	50	55	37	209	16%	89%
55-60	55	60	25	234	11%	100%
			234			

Tabela 3: Szereg rozdzielczy i wartości skumulowane

Teraz obliczmy średnią arytmetyczną. Aby to zrobić, potrzebujemy następującej formuły:

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{k} X_i n_i$$

w której X – środek przedziału x_i. Wtedy znajdziemy X.

Wiek kobiet	**ni**	**X**	**X*ni**
15-20	18	17,5	315
20-25	28	22,5	630
25-30	21	27,5	577,5
30-35	33	32,5	1072,5
35-40	21	37,5	787,5
40-45	32	42,5	1360
45-50	19	47,5	902,5
50-55	37	52,5	1942,5
55-60	25	57,5	1437,5
	234		**9025**

Tabela 4: Środek przedziłu

Otrzymujemy wartość średniej arytmetycznej równą:

$$\overline{X} = \frac{1}{234} \cdot 9025 = 38,6$$

Aby móc wyciągnąć pierwsze wnioski na temat asymetrii rozkładu cechy, musimy znaleźć wartości kwartylów (czyli mediany) i dominanty. Zróbmy to w następujący sposób:

$$Q_1 = x_k + \left(\frac{n}{4} - \sum_{i=1}^{k-1} n_i\right)\frac{h}{n_k}$$

$$Q_2 = Me = x_k + \left(\frac{n}{2} - \sum_{i=1}^{k-1} n_i\right)\frac{h}{n_k}$$

$$Q_3 = x_k + \left(\frac{3 \cdot n}{4} - \sum_{i=1}^{k-1} n_i\right)\frac{h}{n_k}$$

gdzie

- x_k – dolna granica przedziału, w której znajduje się wymagany kwartyl
- n_k – liczebność predziału, w którym znajduje się wymagany kwartyl
- h – długość przedziału klasowego

Skorzystamy z powyższej tabeli 3. Mamy:

$$Q_1 = 25 + (\frac{234}{4} - 46) \cdot \frac{5}{21} = 28,0$$

$$Q_2 = Me = 35 + (\frac{234}{2} - 100) \cdot \frac{5}{21} = 39,0$$

$$Q_3 = 50 + (\frac{3 \cdot 234}{4} - 172) \cdot \frac{5}{37} = 50,5$$

W podobny sposób obliczymy dominantę:

$$D = x_k + \frac{n_k - n_{k-1}}{(n_k - n_{k-1}) + (n_k - n_{k+1})} \cdot h$$

gdzie

- x_k – dolna granica przedziału, w której znajduje się dominanta
- n_k – liczebność predziału, w którym znajduje się dominanta
- n_{k-1} – liczebność predziału,poprzedzającego przedział dominanty
- n_{k+1} – liczebność predziału,następującego przedział dominanty
- h – długość przedziału klasowego

Mamy:

$$D = 50 + \frac{37 - 19}{(37 - 19) + (37 - 25)} \cdot 5 = 53$$

Dzięki uzyskanym danym możemy określić symetrię rozkładu cechy.

$$\overline{X} < Me < D$$

To nam mówi o rozkładzie o skośności ujemnej (tzn lewostronnej)

2.3 Obliczenia

Do obliczenia wszystkich pozostałych parametrów będziemy potrzebować poniższej tabeli.

$X - \overline{X}$	$(X - \overline{X})^2 n_i$	$(X - \overline{X})^3 n_i$	$(X - \overline{X})^4 n_i$	$\lvert X - \overline{X} \rvert n_i$
-21,1	7989,87	-168331,6	3546473,8	379,2
-16,1	7229,4	-116164,7	1866577,3	449,9
-11,1	2572,7	-28475,5	315177,3	232,4
-6,1	1215,2	-7374,5	44751,1	200,3
-1,1	24,0	-25,6	27,4	22,4
3,9	494,6	1944,8	7646,1	125,8
8,9	1515,7	13537,7	120913,6	169,7
13,9	7181,3	100047,7	1393826,4	515,5
18,9	8960,2	169630,4	3211378,4	473,3
	37182,9	**-35211,3**	**10506771,4**	**2568,5**

Tabela 5: Obliczenia z potęgami

Mając tabelę, znajdźmy pozostałe wartości.

1. Wariancja

$$S^2 = \frac{1}{n} \sum_{i=1}^{n} (X - \overline{X})^2 n_i = \frac{1}{234} \cdot 37182,9 = 158,901$$

2. Odchylenie standardowe

$$S = \sqrt{S^2} = \sqrt{158,901} = 12,606$$

3. Typowy obszar zmienności

$$25,963 = \overline{X} - S < X_{typ} < \overline{X} + S = 51,174$$

4. Odchylenie ćwiartkowe

$$Q = \frac{Q_3 - Q_1}{2} = \frac{50,5 - 28,0}{2} = 11,248$$

5. Odchylenie przeciętne

$$S_d = \frac{1}{n}\sum_{i=1}^{n} |X - \overline{X}| n_i = \frac{1}{234} \cdot 2568,5 = 10,977$$

6. Współczynnik zmienności

$$V = \frac{S}{\overline{X}} 100\% = \frac{12,606}{38,6} \cdot 100\% = 33\%$$

7. Współczynnik zmienności pozycyjny

$$V_p = \frac{Q}{Me} 100\% = \frac{11,248}{39} \cdot 100\% = 29\%$$

8. Współczynnik asymetrii

$$A = \frac{m_3}{S^3} = \frac{\frac{1}{n}\sum_{i=1}^{n}(X - \overline{X})^3 n_i}{S^3} = \frac{\frac{1}{234} \cdot (-35211,3)}{(12,606)^3} = -0,075$$

9. Współczynnik asymetrii pozycyjny

$$W_p = \frac{Q_3 + Q_1 - 2Q_2}{Q_3 - Q_1} = \frac{50,5 + 28,0 - 2 \cdot 39,0}{50,5 - 28,0} = -27,969$$

10. Współczynnik koncentracji

$$W_k = \frac{m_4}{S^4} = \frac{\frac{1}{n}\sum_{i=1}^{n}(X - \overline{X})^4 n_i}{S^4} = \frac{\frac{1}{234} \cdot (10506771,4)}{(12,606)^4} = 1,778$$

11. Współczynnik eksesu

$$W_e = W_k - 3 = 1,778 - 3 = -1,222$$

3 Wykresy

3.1 Wykres pudełkowy

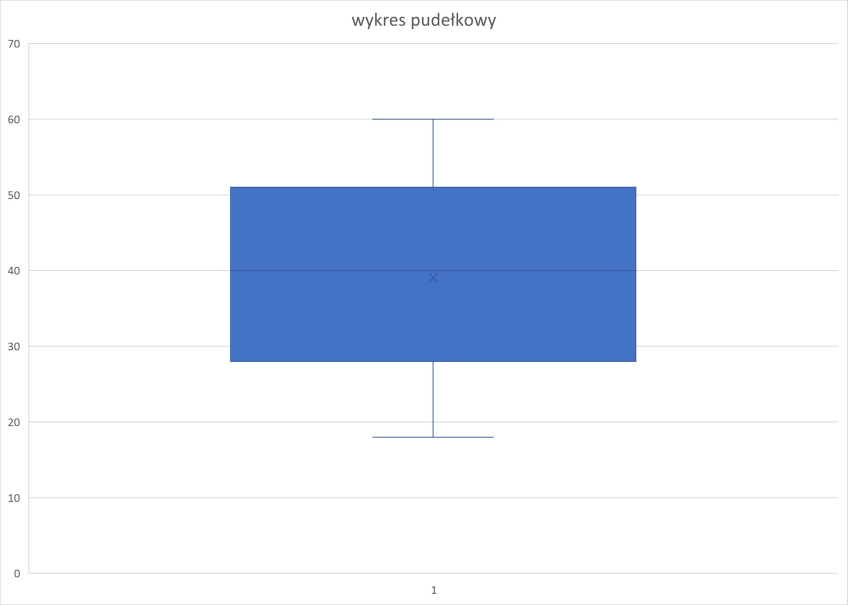

Rysunek 1: Wykres pudełkowy

3.2 Histogram liczebności

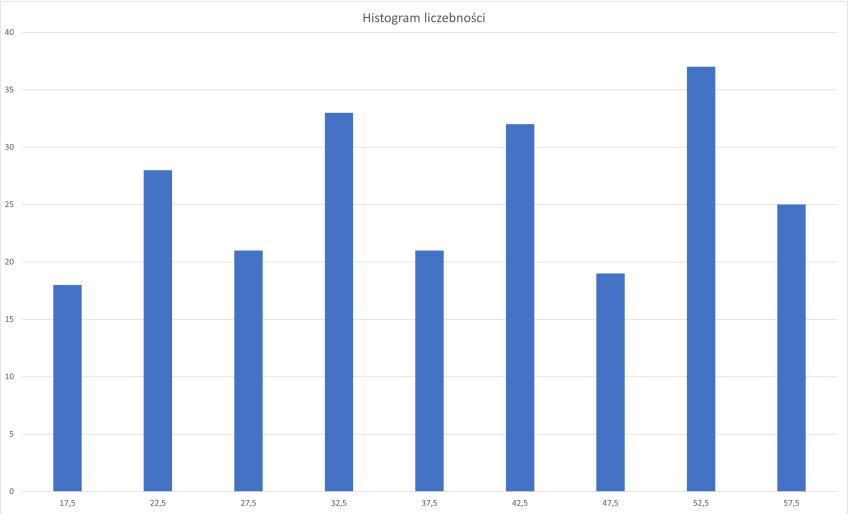

Rysunek 2: Histogram liczebności

3.3 Histogram liczebności skumulowanych

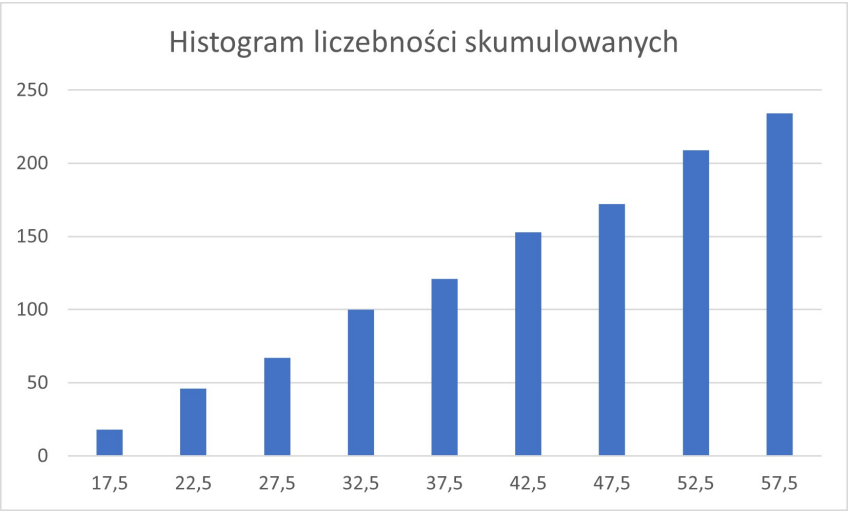

Rysunek 3: Histogram liczebności skumulowanych

3.4 Wielobok liczebności

Rysunek 4: Wielobok liczebności

3.5 Wielobok liczebności skumulowanych

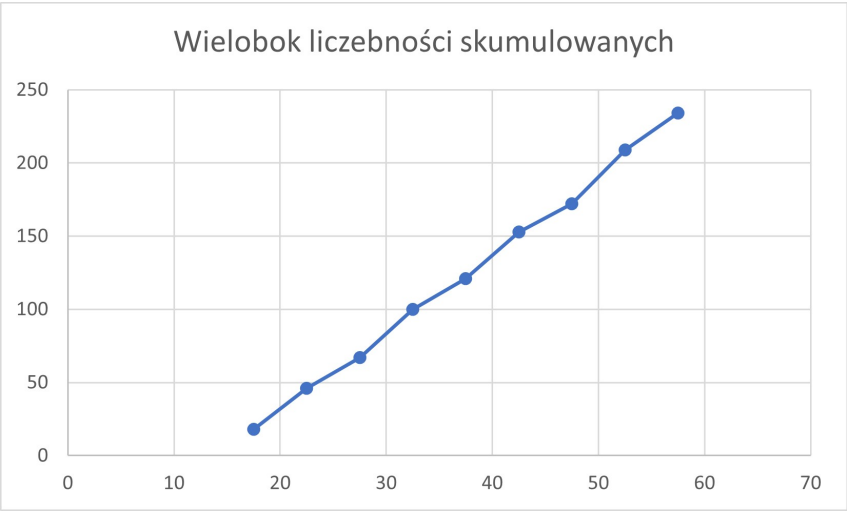

Rysunek 5: Wielobok liczebności skumulowanych

4 Wyniki projektu

4.1 Podsumowsnie obliczeń

Aby mieć pojęcie o analizie naszej próbki, musimy skomentować każdy z uzyskanych wyników, których wartości można porównać z odpowiednymi jednostkami miary

Otrzymaliśy:

1. $V = 33\%$, $30\% < V < 40\%$,
   co można potraktować jako umiarkowane zróżnicowanie cechy. Nasz współczynnik zmienności wynosi więcej niz 30%, co oznacza, że większość opcji odbiega od średniej, a wybrana przeze mnie populacja nie jest jednorodna.

   $V_p = 29\%$, $20\% < V_p < 30\%$,
   tutaj mamy śilne zróżnicowanie cechy, ale ta wartość jest bliska do V.

2. $Q = 11,248$
   ta liczba jest parametrem, określającym odchylenie wartości cechy od mediany (w naszym przypadku Me wynośi 39,0, wtedy wartości próby odchylają się od nią na Q, tzn na $11,248$.

3. $A = -0,075$
   $A < 0$, wtedy asymetria rozkładu jest lewostronna.

   $W_p = -27,969$
   ten współczynnik asymetrii jest wyznaczony za pomocą wykorzystywania kwartyle i też ma wartość $W_p < 0$, co mówi o asymetrii lewostronnej.

4. $W_k = 1,778$, $W_e = -1,222$
   $W_k < 3$, $W_e < 0$ z tego wynika, że spłaszczenie jest mniejsze niż normalne oraz że

dane są częstsze i nie są silnie zgrupowane wokół średniej.

4.2 Podsumowanie wykresów

- Za pomocą wykresu pudełkowego możemy łatwo uzyskać wartość średniej, a także znaleźć element maksymalny i minimalny oraz pierwszy i trzeci kwartyl próby. W naszym przypadku nie trudno zauważyć, że średnia wynosi okolo 40 $(38,6)$, Max i Min wynoszą 60 i ≈ 20 (w rzeczywistości 18), Q1 i Q3 są w przebliżeniu 30 i 50 odpowiednio (28 i $50,5$).

- Histogram liczebności pomaga przedstawić w sposób graficzny częstość występowania jakiejś zmiennej w danym przedziale. Możemy dowiedzieć się o ilości przedziałów, długości jednego przedziału i ilości elementów, znajdujących się w pewnym przedziale. Dla naszej próbki możemy zauważyć, że ilość danych w przedziałach zmienia się skokowo i po kolei maleje a rośnie. Dla histogramu liczebności skumulowanych dane w przedziałach rosną w oczywisty sposób.

- Za pomocą wieloboku liczebności możemy również uzyskać liczbę przedziałów, zauważyć skoki liczby elementów w nim występujących, a także uzyskać przybliżoną wartość średniego elementu w przedziale. W wykresie o liczebnościach skumulowanych łamana rośnie w oczywisty sposób.

Podsumowując, możemy stwierdzić, że spośród wszystkich ankietowanych kobiet to właśnie kobiety w wieku od 50 do 55 lat charakteryzują się największą zachorowalnością, stanowiąc 16% ogółu. Najmniej powszechna tendencja do zaburzeń psychicznych występuje u dziewcząt w wieku 15–20 lat.Najczęstszy wiek zachorowania na choroby psychiczne u kobiet to 53 lata. Otrzymaliśmy wartość średniej i mediany równą 38,6 i 39,0 odpowiednio. Chociaż średnia może nie być całkowicie obiektywnym odzwierciedleniem danych, ponieważ dane mogą przyjmować bardzo duże lub bardzo małe wartości, otrzymaliśmy bardzo bliskie obliczenia.
Zapewne wpływ na to miały szczególne przyczyny i zdarzenia, jakich doświadczyły kobiety w różnych okresach życia, jednak jest to już zupełnie inny temat do analizy, a odpowiedzi na interesujące pytania można znaleźć w załączonej przeze mnie książce.

Literatura

[1] U.Nuber, *WHO AM I WITHOUT YOU? Why Women Become Depressed - And How They Can Find Themselves*,2012.