Wszechstronna analiza współzależności (korelacji) wieku studentów i uzyskanych przez nich ocen akademickich

Sofiya Dreka
nr albumu 180829
Matematyka stosowana i analiza danych, 1 rok

1 marca 2026

1 Wstęp

Często można spotkać się z opinią, że sukces akademicki i wyniki w nauce zależą od wieku, który z kolei jest ściśle powiązany z ilością zdobytego w określonym czasie doświadczenia. Dlatego do tej analizy przygotowałam próbę z 25 par obserwacji dotyczących je współzależności składających się ze zmiennej objaśniającej (wieku) i zmiennej objaśnianej (oceny). Za ich pomocą obliczymy, czy rzeczywiście tak jest i jak wyniki w nauce zależą od wieku studentów.
Temat ten wydaje mi się bardzo interesujący przede wszystkim dlatego, że sama jestem studentką. Również powodem tego wyboru była chęć sprawdzenia, czy rzeczywiście istnieje związek pomiędzy tymi dwiema wielkościami i czy stwierdzenia o tym, że z ciągiem wieku nauka zaczyna być znacznie łatwiejsza, mają sens. Musimy więc albo zgodzić się z popularną opinią, albo obalić ją z punktu widzenia matematyki i statystyki opisowej. Warto zaznaczyć, że bedę korzystała z danych zebranych przez zainteresowane strony w sposób samodzielny, czyli ze strony internetowej *Kaggle* [1].
Uwaga! Oceny otrzymywane przez studentów liczone są w skali dziesiętnej, a wiek przyjmuje wartości od 18 do 33 lat.

2 Analiza

2.1 Dane źródłowe

Umieśćmy w tabeli pare obserwacji dotyczących współzależności wieku i uzyskanych ocen, które zostaną przeanalizowane.

[1] https://www.kaggle.com/datasets/hopesb/student-depression-dataset

x_i	y_i
33	9
24	6
31	7
28	6
25	8
29	6
30	10
30	8
28	10
31	8
24	6
33	7
27	7
19	9
29	6
25	9
20	7
19	7
25	8
29	10
29	9
25	7
23	6
18	6
20	7

Tabela 1: Dane źródłowe

Przejdźmy teraz do analizy współzależności podanych cech.

2.2 Współczynnik korelacji

Żeby odpowiedzieć na pytanie, czy wiek i oceny są ze sobą powiązane, należy obliczyć współczynnik korelacji mędzy nimi, czyli współczynnik korelacji Pearsona. Dlatego skorzystamy z następnej formuły:

$$r = \frac{S_{xy}}{S_x S_y}$$

gdzie

$$S_{xy} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{n}, \qquad S_x = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n}}, \qquad S_y = \sqrt{\frac{\sum_{i=1}^{n}(y_i - \bar{y})^2}{n}}$$

$$\bar{x} - \text{średnia wieku}, \qquad \bar{y} - \text{średnia ocen}.$$

W dalszych obliczeniach bedę zaokrąglała wyniki do 2 miejsc po przecinku.
(Tabela z niezbędnymi obliczeniami będzie znajdowała się poniżej 2)
Dokonujmy obliczenia:

- $\bar{x}$, $\bar{y}$

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n} = \frac{\sum_{i=1}^{25} x_i}{25} = 26,16, \qquad \bar{y} = \frac{\sum_{i=1}^{n} y_i}{n} = \frac{\sum_{i=1}^{25} y_i}{25} = 7,56$$

- S_x

$$S_x^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n} = \frac{479,36}{25} = 19,17, \qquad S_x = \sqrt{19,17} = 4,38$$

- S_y

$$S_y^2 = \frac{\sum_{i=1}^{n}(y_i - \bar{y})^2}{n} = \frac{46,16}{25} = 1,85, \qquad S_y = \sqrt{1,82} = 1,36$$

- S_{xy}

$$S_{xy} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{n} = \frac{42,76}{25} = 1,71$$

Teraz, mając wszystkie niezbędne obliczenia, możemy uzyskać współczynnik korelacji Pearsona r:

$$r = \frac{S_{xy}}{S_x S_y} = \frac{1,71}{4,38 \cdot 1,36} = 0,29$$

Im większa jego wartość bezwzględna, tym silniejsza jest zależność liniowa między zmiennymi. W naszym przypadku r wynosi 0,29 , co mówi o bardzo słabej korelacji mędzy wiekiem i ocenami oraz o dodatnim kierunku związku.

$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$
6,84	1,44	9,85	46,79	2,07
-2,16	-1,56	3,37	4,67	2,43
4,84	-0,56	-2,71	23,43	0,31
1,84	-1,56	-2,87	3,39	2,43
-1,16	0,44	-0,51	1,35	0,19
2,84	-1,56	-4,43	8,07	2,43
3,84	2,44	9,37	14,75	5,95
3,84	0,44	1,69	14,75	0,19
1,84	2,44	4,49	3,39	5,95
4,84	0,44	2,13	23,43	0,19
-2,16	-1,56	3,37	4,67	2,43
6,84	-0,56	-3,83	46,79	0,31
0,84	-0,56	-0,47	0,71	0,31
-7,16	1,44	-10,31	51,27	2,07
2,84	-1,56	-4,43	8,07	2,43
-1,16	1,44	-1,67	1,35	2,07
-6,16	-0,56	3,45	37,95	0,31
-7,16	-0,56	4,01	51,27	0,31
-1,16	0,44	-0,51	1,35	0,19
2,84	2,44	6,93	8,07	5,95
2,84	1,44	4,09	8,07	2,07
-1,16	-0,56	0,65	1,35	0,31
-3,16	-1,56	4,93	9,99	2,43
-8,16	1,56	12,773	66,59	2,43
-6,16	-0,56	3,45	37,95	0,31
		42,76	**479,36**	**46,16**

Tabela 2: Obliczenia dla współczynnika korelacji

Możemy określić siłę korelacji za pomocą następującej relacji:

$$-S_x \cdot S_y \leq S_{xy} \leq S_x \cdot S_y$$
$$-4,38 \cdot 1,36 \leq 1,71 \leq 4,38 \cdot 1,36$$
$$-5,96 \leq 1,71 \leq 5,96$$

Widzimy, że S_{xy} znajduje się stosunkowo blisko prawej strony nierówności, co twierdzi o związku dodatnim.

2.3 Prosta regresji, wartości modelowe i wsp. determinacji

Teraz wyznaczmy prostą regresji.
Regresja liniowa – funkcja regresji, która ma postać funkcji liniowej $y = \beta_0 + \beta_1 x$, gdzie:

$$\beta_1 = \frac{S_{xy}}{S_x^2}, \qquad \beta_0 = \bar{y} - \beta_1 \bar{x}$$

Mając wszystkie dane obliczymy:

$$\beta_1 = \frac{S_{xy}}{S_x^2} = \frac{1,71}{19,17} = 0,09$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x} = 7,56 - 0,09 \cdot 26,16 = 5,23$$

Więc, otrzymaliśmy następującą postać prostej regresji:

$$\boxed{y = 5,23 + 0,09x}$$

Mając formułę prostej regresji, możemy obliczyć nie tylko nowe interesujące nas wartości ocen w zależności od wybranego w sposób dowolny wieku, ale przede wszystkim znaleźć wartości modelowe dla naszych dannych. Aby je uzyskać, należy podstawić do wzoru wszystkie 25 początkowych wartości wieku.
(Dane bedą znajdowały się w poniższej tabeli 3 wraz z kolejnymi obliczeniami).

Dalej należy obliczyć współczynnik determinacji i skorygowany współczynnik determinacji. Skorzystamy z następujących wzorów:

$$R^2 = \frac{SSM}{SST} = \frac{\sum_{i=1}^{n}(\widehat{y}_i - \bar{y})^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}, \qquad \bar{R}^2 = R^2 - \frac{1}{n-(k+1)}\left(1 - R^2\right)$$

gdzie k to liczba zmiennych objaśniających (u nas $k = 1$, czyli wiek)

- R^2

$$R^2 = \frac{SSM}{SST} = \frac{\sum_{i=1}^{n}(\widehat{y}_i - \bar{y})^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} = \frac{3,81}{46,16} = 0,08$$

  R^2 informuje nas, że uzyskana ocena tylko na 8% zależy od wieku studenta. Pozostałe 92% można wytłumaczyć innymi kryteriami (na przykład liczbą godzin snu, stanem zdrowia itp.)

- $\bar{R}^2$

$$\bar{R}^2 = R^2 - \frac{1}{n-(k+1)}\left(1 - R^2\right) = 0,08 - \frac{1}{25-2}(1 - 0,08) = 0,04$$

R^2 wynosi tylko 0,08, co mówi nam o niezadowalającym stopniu dopasowania modelu tzn. prosta regresji jest źle dopasowana do danych.

$(y_i - \bar{y})^2$	$\widehat{y}_i$	$\widehat{y}_i - \bar{y}$	$(\widehat{y}_i - \bar{y})^2$
2,07	8,17	0,61	0,37
2,43	7,37	-0,19	0,04
0,31	7,99	0,43	0,19
2,43	7,72	0,16	0,03
0,19	7,46	-0,10	0,01
2,43	7,81	0,25	0,06
5,95	7,90	0,34	0,12
0,19	7,90	0,34	0,12
5,95	7,72	0,16	0,03
0,19	7,99	0,43	0,19
2,43	7,37	-0,19	0,04
0,31	8,17	0,61	0,37
0,31	7,63	0,07	0,01
2,07	6,92	-0,64	0,41
2,43	7,81	0,25	0,06
2,07	7,46	-0,10	0,01
0,31	7,01	-0,55	0,30
0,31	6,92	-0,64	0,41
0,19	7,46	-0,10	0,01
5,95	7,81	0,25	0,06
2,07	7,81	0,25	0,06
0,31	7,46	-0,10	0,01
2,43	7,28	-0,28	0,08
2,43	6,83	-0,73	0,53
0,31	7,01	-0,55	0,30
46,16			**3,81**

Tabela 3: Wartości modelowe i obliczenia z nimi

2.4 Odchylenie standardowe składnika resztowego, błędy standardowe wsp-ów regresji

Teraz zbadamy jakość otrzymanej prognozy. Skorzystamy z formuł:

$$S_e = \sqrt{\frac{\sum\limits_{i=1}^{n} e_i^2}{n-2}} = \sqrt{\frac{\sum\limits_{i=1}^{n}(y_i - \widehat{y}_i)^2}{n-2}}, \qquad S_{\beta 1} = \sqrt{\frac{S_e^2}{\sum\limits_{i=1}^{n}(x_i - \bar{x})^2}}, \qquad S_{\beta 0} = \sqrt{\frac{S_e^2 \sum\limits_{i=1}^{n} x_i^2}{n \sum\limits_{i=1}^{n}(x_i - \bar{x})^2}}$$

(Tabela z niezbędnymi obliczeniami będzie znajdowała się poniżej)

- S_e

$$S_e = \sqrt{\frac{\sum\limits_{i=1}^{n}(y_i - \widehat{y}_i)^2}{n-2}} = \sqrt{\frac{42,35}{23}} = 1,36$$

- $S_{\beta 1}$

$$S_{\beta 1} = \sqrt{\frac{S_e^2}{\sum\limits_{i=1}^{n}(x_i - \bar{x})^2}} = \sqrt{\frac{1,36^2}{479,36}} = 0,06$$

- $S_{\beta 0}$

$$S_{\beta 0} = \sqrt{\frac{S_e^2 \sum\limits_{i=1}^{n} x_i^2}{n \sum\limits_{i=1}^{n}(x_i - \bar{x})^2}} = \sqrt{\frac{1,36^2 \cdot 17588}{25 \cdot 479,36}} = 1,64$$

To, co obliczyliśmy – błędy standardowe współczynników regresji –, należy rozumieć następująco:

$$\begin{gathered} \beta_1 - S_{\beta_1} \leq \beta_1 \leq \beta_1 + S_{\beta_1} \\ 0,03 \leq 0,09 \leq 0,15 \end{gathered} \tag{1}$$

$$\begin{gathered} \beta_0 - S_{\beta_0} \leq \beta_0 \leq \beta_0 + S_{\beta_0} \\ 3,58 \leq 5,23 \leq 6,87 \end{gathered} \tag{2}$$

czyli:

$$y = \underset{[\pm 1,64]}{5,23} + \underset{[\pm 0,06]}{0,09x}$$

$(y_i - \widehat{y})_i$	$(y_i - \widehat{y}_i)^2$	x_i^2
0,83	0,69	1089
-1,37	1,87	576
-0,99	0,98	961
-1,72	2,97	784
0,54	0,30	625
-1,81	3,29	841
2,10	4,40	900
0,10	0,01	900
2,28	5,18	784
0,01	0,00	961
-1,37	1,87	576
-1,17	1,37	1089
-0,63	0,40	729
2,08	4,32	361
-1,81	3,29	841
1,54	2,38	625
-0,01	0,00	400
0,08	0,01	361
0,54	0,30	625
2,19	4,78	841
1,19	1,41	841
-0,46	0,21	625
-1,28	1,63	529
-0,83	0,69	324
-0,01	0,00	400
	42,35	**17588,00**

Teraz mamy wszystkie niezbędne parametry, aby sporządzić najdokładniejszą prognozę dla kilku ustalonych w sposób dowolny wartości x, wieku.
Wybrałam następujące wartości x : 21, 22, 26, 32. Podstawimy je do formuły:

- $y(21)$

$$y(21) = 5,23 + 0,09 \cdot 21 = 7,10 \approx 7$$

  Uwzględnimy teraz obliczone wcześniej odchylenie standardowe składnika resztowego:

$$7,10 - 1,36 < y(21) < 7,10 + 1,36$$

$$5,74 < y(21) < 8,46$$

  Oznacza to, że teoretycznie możemy spodziewać się, że osoba w wieku 21 lat uzyska ocenę w tym przedziale.
  Zróbmy teraz to samo dla pozostałych wartości.

- $y(22)$

$$y(22) = 5,23 + 0,09 \cdot 22 = 7,19 \approx 7$$

$$7,19 - 1,36 < y(22) < 7,19 + 1,36$$
$$5,83 < y(22) < 8,55$$

- $y(26)$

$$y(26) = 5,23 + 0,09 \cdot 26 = 7,55 \approx 8$$
$$7,55 - 1,36 < y(26) < 7,55 + 1,36$$
$$6,19 < y(26) < 8,91$$

- $y(32)$

$$y(32) = 5,23 + 0,09 \cdot 32 = 8,08 \approx 8$$
$$8,-8 - 1,36 < y(32) < 8,08 + 1,36$$
$$6,72 < y(32) < 9,44$$

3 Wykresy

1. Wykres 1.
   Możemy zauważyć, że analizowany wiek przyjmuje wartości od 18 do 33, a oceny, uzyskane przez uczniów są od 6 do 10. Oznacza to, że pomimo oceny są liczone w skali dziesiątnej, nikt ze wziętej próbki nie uzyskał oceny mniejszej niż 6.
   Z wykresu widać, że korelacja pomiędzy danymi jest taka słaba, że nawet można powiedzieć że ona nie istnieje. Ale biorąc pod uwagę obliczony wsp. korelacji ($r = 0,29$) ona istnieje i jest słaba i dodaze względu na silę.

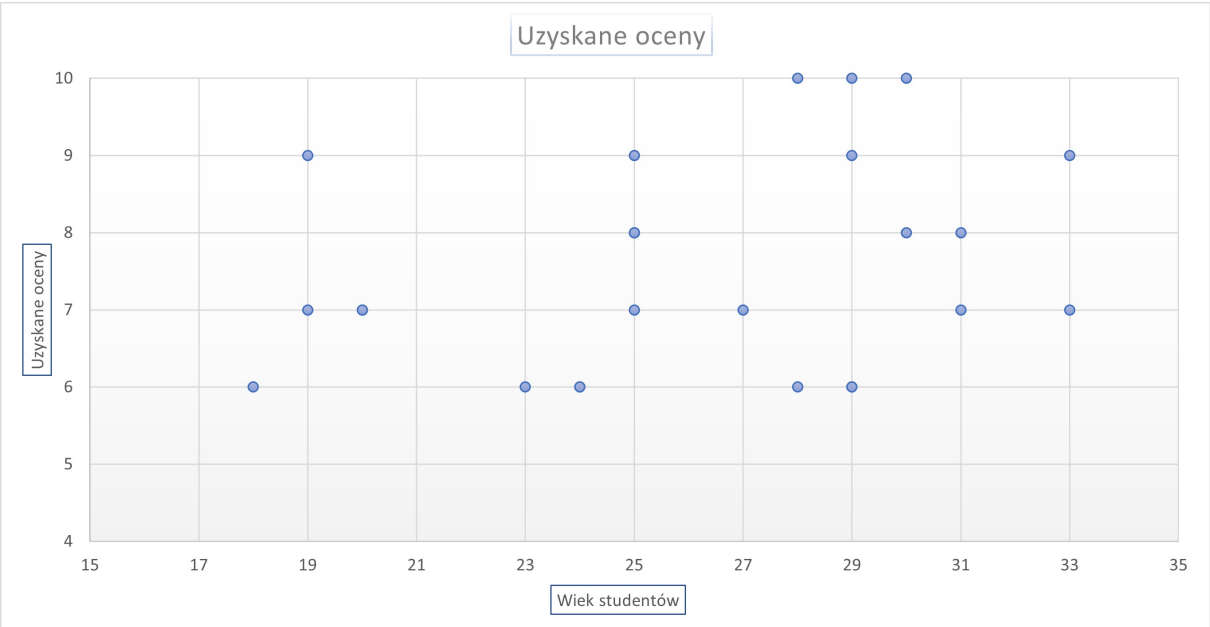

Rysunek 1: Wykres punktów z doświadczenia

2. Wykres 2.
   Do poprzedniego wykresu dodaliśmy prostą regresji, stosując metodę najmniejszych kwadratów. Za ją pomocą widzimy, że dane wyglądają na chaotyczne i korelacja między nimi jest małe widoczna z powodu wielkiego rozrzutu, ale jednak można zauważyć słaby związek pomiędzy "kropkami"i prostej.

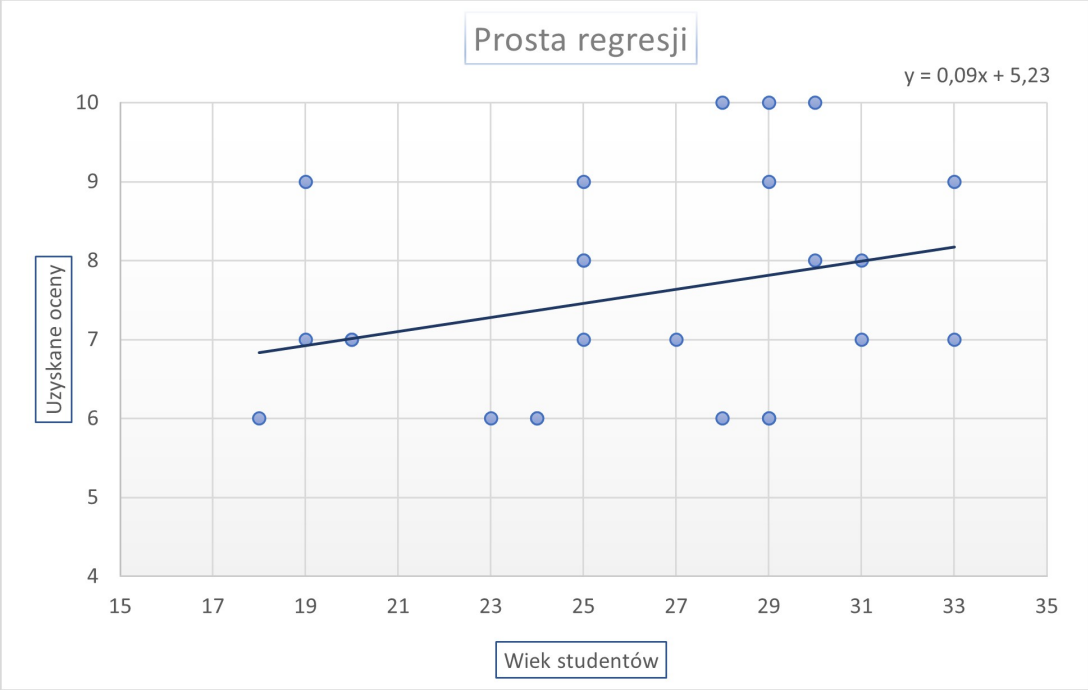

Rysunek 2: Wykres prostej regresji

3. Wykres 3
   Poszczególne punkty nie leżą idealnie na linii regresji, tylko wzrostają dla tych samych wartości leżących na linii poziomej (ocenach). Oznacza to, że mamy bardzo małe szanse na uzyskanie dokładnych wyników poprzez podstawienie do uzyskanego wzoru wieku, co oznacza także małą zależność pomiędzy badanymi cechami (wiekiem oraz ocenami). Należy pomiętać, że model regresji nigdy nie jest idealnie dopasowany do danych. Występowanie błędów oszacowania jest czymś naturalnym, ponieważ każdy model statystyczny jest pewnym uproszczeniem rzeczywistości.

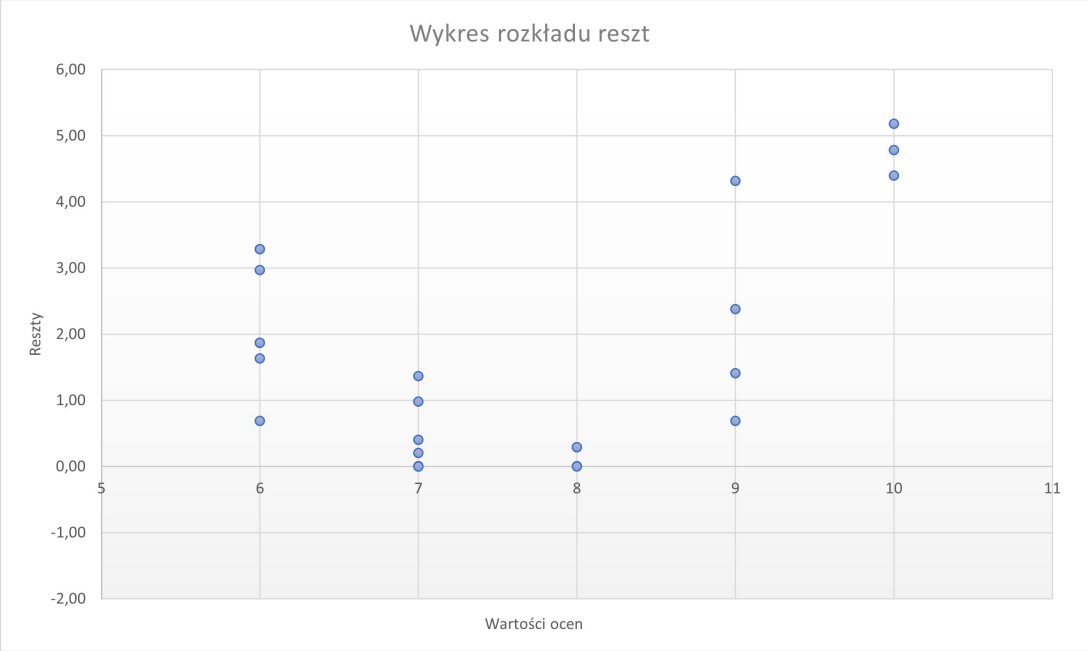

Rysunek 3: Wykres rozkładu reszt

4 Wyniki

Sprawdziliśmy zależność jednej wartości (ocen akademickich) od drugiej (wieku) i tu są wyniki, które otrzymaliśmy:

1. Współczynnik korelacji Pearsona r winosi 0,29, co jest wskaźnikiem raczej niskim. Sugeruje to, że korelacja pomiędzy obydwoma wartościami jest bardzo słaba i mieści się w przedziale (0,2-0,4). Możemy stwierdzać, że stereotypowa opinia, o której mówiliśmy na początku, prawie nie ma podstaw i zupełnie nie należy oczekiwać, że osoba w młodszym wieku będzie miała niższą ocenę niż osoba dorosła.
   Siła korelacji jest dodatnia, możemy to zweryfikować zarówno z obliczeń, jak i ze zbudowanego wykresu. Oznacza to, że dane odnoszą się do siebie w bezpośredniej proporcji, czyli "im większe x, tym większe y".

2. Zbudowaliśmy także wzór na prostą regresji, dzięki której możemy obliczyć ocenę teoretyczną w zależności od dowolnego wieku. Oczywiście nie da się tego zrobić z idealną dokładnością, jak wynika z obliczeń 2.4, ale zawsze można wskazać pewne granice.

3. Współczynnik daterminacji R^2 wyniosł 0,08. R^2 zawsze przyjmuje wartości od 0 do 1. Im wartość współczynnika jest bliższa 1, tym silniejsza jest zależność. Oceniając modele regresji, interpretuje się to jako dopasowanie modelu do danych. Uzyskaliśmy bardzo niski współczynnik determinacji, co oznacza, że model ledwo pasuje do danych.